

Entrega 2 – Análisis Exploratorio y Preprocesamiento del Corpus AG News

Alumno: Amilcar Jesús Fernández
Comisión: 90435
Fecha: 06/08/2026

Objetivo

El objetivo de esta entrega fue realizar un análisis exploratorio del corpus AG News y desarrollar un pipeline de preprocesamiento orientado a la preparación de los datos para tareas de clasificación automática de noticias. Para ello se analizaron las características generales del conjunto de datos, la distribución de las clases y la longitud de los documentos. Posteriormente se implementó un proceso de limpieza, normalización y lematización del texto, cuya calidad fue validada mediante el análisis de palabras frecuentes y n-gramas, obteniendo un corpus consistente para las etapas posteriores del proyecto.

Resumen del pipeline de preprocesamiento

Se implementó un pipeline de preprocesamiento compuesto por las siguientes etapas:

- Conversión de todos los documentos a minúsculas para unificar el vocabulario.
- Eliminación de URLs y caracteres no alfabéticos mediante expresiones regulares.
- Tokenización utilizando el modelo `en_core_web_sm` de spaCy.
- Eliminación de signos de puntuación y palabras vacías (stopwords).
- Lematización de los términos para reducir las distintas formas flexionadas a una representación común.
- Eliminación de un conjunto específico de términos considerados ruido (agencias de noticias, etiquetas HTML y otros artefactos técnicos), identificado durante el análisis exploratorio.

El objetivo del pipeline fue conservar la información semántica relevante del corpus reduciendo simultáneamente la variabilidad léxica y el ruido presente en los textos originales.

Distribución de clases




Figura 1. Distribución de documentos por categoría temática.

El corpus utilizado contiene 8.000 documentos de entrenamiento distribuidos uniformemente entre las cuatro categorías temáticas (Business, Sci_Tech, Sports y World), con 2.000 documentos por clase. Esta distribución balanceada evita sesgos derivados del desbalance de clases y facilita la comparación objetiva del desempeño de los modelos de clasificación.

Longitud de los documentos




Figura 2. Distribución de la longitud de los documentos y percentil 95.

La longitud de los documentos presenta una distribución relativamente concentrada alrededor de una media cercana a 38 palabras. El percentil 95 se ubicó en 53 palabras, indicando que la gran mayoría de las noticias poseen una extensión moderada. Esta información resulta relevante para las etapas posteriores del proyecto, ya que proporciona una referencia objetiva para la definición del tamaño máximo

de secuencia en modelos basados en transformadores.

Tablas de N-gramas

Top-20 bigramas

#	Bigrama	Frecuencia
1	new york	419
2	oil price	197
3	united states	167
4	prime minister	139
5	official say	115
6	say thursday	102
7	say monday	101
8	red sox	98
9	say tuesday	98
10	los angeles	96
11	san francisco	96
12	president bush	93
13	say wednesday	90
14	say friday	89
15	year old	88
16	mobile phone	72
17	wall street	71
18	microsoft corp	70
19	profile research	69
20	quote profile	69

Top-20 trigramas

#	Trigrama	Frecuencia
1	quote profile research	69
2	boston red sox	37
3	new york stock	37
4	high oil price	27
5	canadian press canadian	26
6	serif arial helvetica	26
7	prime minister ariel	26
8	ms sans serif	26
9	verdana ms sans	26
10	face verdana ms	26
11	press canadian press	26
12	sans serif arial	26
13	arial helvetica size	26
14	helvetica size color	26
15	font face verdana	26
16	minister ariel sharon	25
17	secretary state colin	22
18	state colin powell	22
19	president vladimir putin	21
20	president george bush	21

Interpretación. Los n-gramas más frecuentes representan principalmente entidades geográficas, económicas y políticas, coherentes con la temática periodística del corpus. El análisis exploratorio permitió identificar y reducir el ruido técnico mediante el refinamiento iterativo del pipeline de preprocesamiento, obteniendo un corpus más consistente y adecuado para las siguientes etapas del proyecto, orientadas a la representación vectorial y la clasificación automática de noticias.

Conclusión

El análisis exploratorio confirmó que el corpus presenta una distribución balanceada entre sus cuatro categorías y documentos de longitud relativamente homogénea, características favorables para el entrenamiento de modelos de clasificación. El pipeline de preprocesamiento permitió reducir significativamente el ruido presente en los textos mediante normalización, lematización, eliminación de palabras vacías y filtrado de artefactos técnicos detectados durante el EDA. La validación mediante

palabras frecuentes y n-gramas mostró que el vocabulario resultante representa adecuadamente el contenido periodístico del corpus. En conjunto, estas tareas permitieron obtener un conjunto de datos consistente y preparado para las siguientes etapas del proyecto, centradas en la representación vectorial mediante TF-IDF y el entrenamiento del clasificador.