

Entrega 2 – Análisis Exploratorio y Preprocesamiento del Corpus AG News

Alumno: Amilcar Jesús Fernández

Comisión: 90435

Fecha: 06/08/2026 | Revisión: 12/08/2026

Objetivo

El objetivo de esta entrega fue realizar un análisis exploratorio del corpus AG News y desarrollar un pipeline de preprocesamiento orientado a la preparación de los datos para tareas de clasificación automática de noticias. Para ello se analizaron las características generales del conjunto de datos, la distribución de las clases y la longitud de los documentos. Posteriormente se implementó un proceso de limpieza, normalización y lematización del texto, cuya calidad fue validada mediante el análisis de palabras frecuentes y n-gramas, obteniendo un corpus consistente para las etapas posteriores del proyecto.

Resumen del pipeline de preprocesamiento

Se implementó un pipeline de preprocesamiento compuesto por las siguientes etapas:

- Conversión de todos los documentos a minúsculas para unificar el vocabulario.
- Eliminación de URLs y caracteres no alfabéticos mediante expresiones regulares.
- Tokenización utilizando el modelo `en_core_web_sm` de spaCy.
- Eliminación de signos de puntuación y palabras vacías (stopwords).
- Lematización de los términos para reducir las distintas formas flexionadas a una representación común.
- Decodificación de entidades HTML escapadas y posterior eliminación de etiquetas HTML.
- Eliminación de un conjunto específico de términos considerados ruido, identificado durante el análisis exploratorio (detalle a continuación).

```
RUIDO = {"lt", "gt", "afp", "quot", "href", "target", "quickinfo", "fullquote", "ap",  
"reuter", "reuters", "com", "www", "http", "https", "s", "u", "b", "t"}
```

Este conjunto agrupa artefactos técnicos del formato original del corpus: fragmentos de entidades HTML (`lt`, `gt`, `quot`), atributos y metadatos de enlaces (`href`, `target`, `quickinfo`, `fullquote`), abreviaturas de agencias de noticias usadas como prefijo de boilerplate (`afp`, `ap`, `reuter`, `reuters`) y restos de URLs (`com`, `www`, `http`, `https`). Las letras sueltas (`s`, `u`, `b`, `t`) corresponden a residuos de un único carácter que persistían tras la eliminación de etiquetas. Ninguno de estos términos corresponde a vocabulario periodístico; la lista se mantuvo deliberadamente acotada a ruido técnico, sin incorporar palabras de alta frecuencia que pudieran ser contenido legítimo.

El objetivo del pipeline fue conservar la información semántica relevante del corpus reduciendo simultáneamente la variabilidad léxica y el ruido presente en los textos originales.

Distribución de clases




Figura 1. Distribución de documentos por categoría temática.

El corpus utilizado contiene 8.000 documentos de entrenamiento distribuidos uniformemente entre las cuatro categorías temáticas (Business, Sci_Tech, Sports y World), con 2.000 documentos por clase. Esta distribución balanceada evita sesgos derivados del desbalance de clases y facilita la comparación objetiva del desempeño de los modelos de clasificación.

Longitud de los documentos




Figura 2. Distribución de la longitud de los documentos y percentil 95.

La longitud de los documentos presenta una distribución relativamente concentrada alrededor de una media cercana a 38 palabras. El percentil 95 se ubicó en **53 palabras**, indicando que la gran mayoría de las noticias poseen una extensión moderada. Este valor (percentil 95 = 53) se adopta como referencia

explícita para la definición del tamaño máximo de secuencia en la etapa de modelado con Transformers.

Tablas de n-gramas

Top-20 bigramas

#	Bigrama	Frecuencia
1	new york	419
2	oil price	197
3	united states	167
4	prime minister	139
5	official say	115
6	say thursday	102
7	say monday	101
8	red sox	98
9	say tuesday	98
10	los angeles	96
11	san francisco	96
12	president bush	93
13	say wednesday	90
14	say friday	89
15	year old	88
16	mobile phone	72
17	wall street	71
18	microsoft corp	70
19	profile research	69
20	quote profile	69

Nota: el top-20 de bigramas es idéntico entre el corpus heredado (utilizado por los modelos de los Notebooks 03 y 04) y el corpus corregido tras la decodificación de entidades HTML — la contaminación por artefactos HTML/CSS detectada afectó únicamente al top-20 de trigramas, no al de bigramas. Por eso se muestra una única versión.

Top-20 trigramas — corpus heredado (utilizado por los modelos 03 y 04)

#	Trigrama	Frecuencia
1	quote profile research	69
2	boston red sox	37
3	new york stock	37
4	high oil price	27
5	canadian press canadian	26
6	serif arial helvetica	26
7	prime minister ariel	26
8	ms sans serif	26
9	verdana ms sans	26
10	face verdana ms	26
11	press canadian press	26
12	sans serif arial	26
13	arial helvetica size	26
14	helvetica size color	26
15	font face verdana	26
16	minister ariel sharon	25
17	secretary state colin	22
18	state colin powell	22
19	president vladimir putin	21
20	president george bush	21

Top-20 trigramas — corpus corregido (tras decodificar entidades HTML antes de eliminar etiquetas)

#	Trigrama	Frecuencia
1	quote profile research	69
2	new york stock	37
3	boston red sox	37
4	high oil price	27
5	press canadian press	26
6	canadian press canadian	26
7	prime minister ariel	26
8	minister ariel sharon	25
9	secretary state colin	22
10	state colin powell	22
11	new york yankees	21
12	president george bush	21
13	president vladimir putin	21
14	crude oil price	20
15	security exchange commission	20
16	international space station	18
17	prime minister tony	17
18	minister tony blair	17
19	los angeles dodger	16
20	st louis cardinal	16

Comparación antes / después. Las filas resaltadas en rojo en la tabla izquierda son los patrones de formato HTML/CSS (nombres de tipografías, atributos de estilo) detectados en el corpus heredado. Tras corregir el pipeline —decodificando entidades HTML antes de eliminar las etiquetas de formato— estos ocho patrones dejaron de aparecer entre los 20 trigramas más frecuentes, y fueron reemplazados por expresiones propias del contenido periodístico ("new york yankees", "crude oil price", "security exchange commission", "international space station", entre otras).

Interpretación. Los n-gramas más frecuentes representan principalmente entidades geográficas, económicas y políticas, coherentes con la temática periodística del corpus. El filtrado se limitó a ruido técnico, preservando expresiones propias del contenido periodístico —nombres de personas, lugares, instituciones y organizaciones— aun cuando presentaran alta frecuencia, para evitar eliminar información potencialmente relevante para la clasificación.

Observación. La verificación posterior identificó los lemas "say" y "take" entre las palabras frecuentes pese al filtrado de stopwords. Esto puede producirse porque el criterio token.is_stop se evalúa sobre el

token antes de incorporar su forma lematizada al corpus procesado. Dado que ambos términos pertenecen al lenguaje natural del dominio periodístico y no constituyen ruido técnico, se decidió no incorporarlos manualmente a la lista de exclusión.

Conclusión

Durante el proceso de limpieza y normalización de los 10.000 documentos que integran el corpus —8.000 destinados a entrenamiento y 2.000 a prueba—, la validación inicial del ruido técnico presente en los textos no tuvo la robustez necesaria. Posteriormente, mediante el análisis de n-gramas, se detectaron términos asociados a etiquetas HTML y estilos de formato que permanecían en el corpus procesado.

La inspección de los documentos originales permitió identificar la causa: parte del HTML se encontraba almacenado mediante entidades escapadas. Como consecuencia, la limpieza inicial eliminaba la simbología asociada a estas entidades, pero no reconocía las etiquetas HTML completas, dejando términos técnicos residuales en el texto. Esta contaminación fue evidenciada particularmente mediante el análisis de bigramas y trigramas. La misma versión histórica del corpus fue posteriormente utilizada tanto por el modelo clásico como por el modelo Transformer.

A partir de este hallazgo, el pipeline del Notebook 02 fue corregido incorporando la decodificación de entidades HTML antes de la eliminación de las etiquetas de formato. Posteriormente se volvió a ejecutar y verificar el flujo completo, desde la carga de los datos hasta la generación y persistencia de los artefactos. Los nuevos análisis de bigramas y trigramas permitieron comprobar que los residuos HTML/CSS identificados dejaron de aparecer entre los resultados principales.

La versión corregida del corpus fue persistida con un nombre diferente, evitando sobrescribir los archivos históricos utilizados por los Notebooks 03 y 04. Esta decisión permite conservar la trazabilidad del experimento y mantener la comparabilidad entre ambas ramas, dado que tanto la Regresión Logística con TF-IDF como DistilBERT con LoRA fueron entrenados y evaluados sobre la misma versión del corpus. Por lo tanto, la limitación detectada no invalida la comparación realizada dentro de las condiciones originales del experimento, aunque sí establece una restricción metodológica que debe ser considerada al interpretar sus resultados.

Se decidió no reentrenar retrospectivamente los modelos con el objetivo de obtener resultados considerados a priori como más favorables o esperables. La corrección del pipeline resulta necesaria para disponer de artefactos más robustos y reutilizables, pero sus posibles efectos sobre el desempeño de los modelos constituyen una nueva cuestión experimental y no un resultado conocido de antemano.

En consecuencia, los hallazgos serán incorporados al Documento 00 de arquitectura como base para nuevas hipótesis de trabajo en una futura expansión del proyecto. Entre ellas, se propone estudiar por separado el efecto de la limpieza estructural del corpus y el de las transformaciones lingüísticas —como la eliminación de stopwords y la lematización— sobre modelos con estrategias de representación diferentes. Esto permitirá evaluar si las decisiones de preprocesamiento que resultan adecuadas para TF-IDF y Regresión Logística producen el mismo efecto sobre un Transformer preentrenado o si cada arquitectura requiere una estrategia de preparación del texto diferente.