

Data Science III — Procesamiento de Lenguaje Natural

Pre-entrega 4 — Fine-tuning de Transformer con LoRA

Proyecto: Clasificación temática de noticias AG News

Modelo: DistilBERT + LoRA

Alumno: Amilcar Fernández

Fecha: 08/08/2026

1. Objetivo

El objetivo de esta etapa es implementar y evaluar un modelo Transformer preentrenado para la clasificación temática de noticias del dataset AG News, utilizando DistilBERT como modelo base y LoRA (Low-Rank Adaptation) como técnica de fine-tuning eficiente.

El experimento busca adaptar el modelo a las cuatro categorías del problema —World, Sports, Business y Sci_Tech— entrenando únicamente una fracción reducida de sus parámetros. Para ello se utiliza una división interna de entrenamiento y validación, manteniendo el conjunto de prueba completamente aislado hasta la evaluación final.

Además del desempeño predictivo, se analiza la eficiencia del ajuste mediante la proporción de parámetros entrenables y el tiempo de entrenamiento. Finalmente, los resultados obtenidos se contrastan con el baseline clásico desarrollado previamente mediante TF-IDF y Regresión Logística, con el objetivo de evaluar si la utilización de un Transformer aporta una mejora suficiente para justificar su mayor complejidad computacional.

2. Datos y preparación del corpus

Se utilizó el corpus AG News previamente preparado en las etapas anteriores del proyecto. El conjunto de trabajo contiene cuatro categorías temáticas balanceadas: World, Sports, Business y Sci_Tech.

Para esta etapa se utilizaron 8.000 documentos de entrenamiento y 2.000 documentos de prueba, con 2.000 y 500 observaciones por categoría, respectivamente. El conjunto de entrenamiento fue dividido internamente de forma estratificada en 6.400 documentos para entrenamiento y 1.600 para validación, preservando la distribución de clases. Los 2.000 documentos de prueba permanecieron aislados durante el entrenamiento y la selección del modelo y fueron utilizados únicamente para la evaluación final.

Las etiquetas categóricas fueron representadas mediante identificadores enteros y los conjuntos fueron convertidos al formato Dataset de Hugging Face para su utilización en el pipeline de tokenización y entrenamiento.

Como entrada textual se reutilizó la variable `text_processed` generada durante el preprocesamiento del corpus. De esta manera se mantuvo la continuidad entre las distintas ramas experimentales del proyecto y se evitó introducir una preparación diferente de los datos exclusivamente para el Transformer.

Para la representación de entrada se utilizó el tokenizer asociado a `distilbert-base-uncased`. La longitud de las secuencias fue analizada nuevamente utilizando este tokenizer y se estableció `MAX_LENGTH = 41`, correspondiente al percentil 95 de las longitudes observadas en el conjunto de entrenamiento. Las secuencias superiores a este límite fueron truncadas y el padding se realizó dinámicamente durante el entrenamiento.

3. Modelo Transformer y configuración LoRA

Se seleccionó DistilBERT (distilbert-base-uncased) como modelo Transformer preentrenado para la clasificación temática. La elección resulta compatible con AG News, cuyo corpus se encuentra en inglés, dado que el modelo base utilizado fue preentrenado sobre texto en este idioma. Además, DistilBERT conserva la arquitectura contextual basada en Transformers de BERT en una versión más compacta, lo que permite reducir el costo computacional del fine-tuning manteniendo capacidad para modelar relaciones contextuales entre los tokens.

Para la tarea se utilizó la variante de DistilBERT destinada a clasificación de secuencias, incorporando una cabeza de clasificación sobre la representación producida por el modelo base para obtener las cuatro categorías de salida.

Sobre el modelo base se aplicó LoRA (Low-Rank Adaptation) mediante la librería PEFT. En lugar de actualizar todos los parámetros de DistilBERT, LoRA incorpora matrices de bajo rango sobre módulos específicos de atención y concentra el entrenamiento en una fracción reducida de los parámetros.

La configuración utilizada fue:

Parámetro	Valor
Modelo base	distilbert-base-uncased
Número de clases	4
r	8
lora_alpha	16
lora_dropout	0,1
Módulos objetivo	q_lin, v_lin
Tipo de tarea	Clasificación de secuencias

Se adoptó $r = 8$ como un rango intermedio, buscando proporcionar capacidad suficiente para adaptar las representaciones del modelo sin incrementar innecesariamente la cantidad de parámetros entrenables para una tarea de clasificación temática de cuatro categorías. Se estableció $\text{lora_alpha} = 16$, equivalente al doble del rango utilizado, con el objetivo de mantener una escala moderada de actualización de los adaptadores.

La configuración resultante dejó 741.124 parámetros entrenables sobre un total de 67.697.672, equivalentes al 1,0948 % del modelo. De esta manera, más del 98 % de los parámetros permanecieron congelados durante el ajuste, concentrando el aprendizaje en los adaptadores LoRA y en los parámetros necesarios para la tarea de clasificación.

4. Configuración y estrategia de entrenamiento

El fine-tuning se realizó en Google Colab utilizando una GPU NVIDIA Tesla T4. Se entrenó durante tres épocas y se evaluó el modelo sobre el conjunto de validación al finalizar cada una de ellas.

La configuración principal de entrenamiento fue:

Parámetro	Valor
Épocas	3
Batch size de entrenamiento	16
Batch size de evaluación	16

Learning rate	2e-5
Weight decay	0,0 (valor por defecto)
Criterio de selección	F1-Score macro
Mejor modelo al finalizar	Sí
Hardware	NVIDIA Tesla T4

Se utilizó el F1-Score macro como métrica principal para la selección del modelo, debido a que permite evaluar el desempeño considerando por igual las cuatro categorías del problema. Aunque el corpus se encuentra balanceado, esta métrica permite complementar el accuracy y observar el rendimiento sin favorecer a una clase particular.

Durante esta etapa, las decisiones de entrenamiento y la selección del mejor estado del modelo se realizaron exclusivamente a partir de los conjuntos de entrenamiento y validación. El conjunto de prueba oficial permaneció aislado y fue utilizado una única vez, una vez finalizado el proceso de ajuste, para estimar el desempeño final.

El entrenamiento completo tomó 78,58 segundos (1,31 minutos). Este tiempo, junto con el reducido porcentaje de parámetros entrenables, muestra la eficiencia computacional obtenida mediante LoRA para adaptar el Transformer a la tarea de clasificación.

5. Evolución del entrenamiento

El comportamiento del modelo fue monitoreado durante las tres épocas mediante la pérdida de entrenamiento, la pérdida de validación y las métricas calculadas sobre el conjunto de validación al finalizar cada una de ellas.

Época	Training Loss	Validation Loss	Accuracy	F1 macro
1	0,8829	0,4213	0,8663	0,8651
2	0,3903	0,3599	0,8781	0,8774
3	0,3639	0,3535	0,8781	0,8774

Durante el entrenamiento se observó una reducción sostenida tanto de la pérdida de entrenamiento como de la pérdida de validación. La training loss descendió de 0,8829 a 0,3639, mientras que la validation loss disminuyó de 0,4213 a 0,3535.

La mejora predictiva se concentró principalmente entre la primera y la segunda época. El accuracy de validación aumentó de 0,8663 a 0,8781 y posteriormente permaneció estable. De manera similar, el F1-Score macro pasó de 0,8651 a 0,8774 y mostró únicamente una variación marginal durante la tercera época, alcanzando 0,8774.

La disminución simultánea de las pérdidas de entrenamiento y validación no muestra, dentro de las tres épocas ejecutadas, una señal de deterioro del desempeño de validación asociada a sobreajuste. Al mismo tiempo, la estabilización de las métricas entre las épocas 2 y 3 indica que las ganancias adicionales ya eran marginales.

6. Evaluación final sobre el conjunto de prueba

Una vez finalizado el entrenamiento y la evaluación sobre validación, se utilizó por primera vez el conjunto de prueba oficial, compuesto por 2.000 documentos balanceados entre las cuatro categorías.

El modelo DistilBERT ajustado mediante LoRA alcanzó los siguientes resultados globales:

Métrica	Resultado
Accuracy	0,8800
Precision macro	0,8813
Recall macro	0,8800
F1-Score macro	0,8804


El desempeño por categoría fue:

Categoría	Precision	Recall	F1-Score	Support
World	0,8871	0,8800	0,8835	500
Sports	0,9658	0,9600	0,9629	500
Business	0,7955	0,8400	0,8171	500
Sci_Tech	0,8768	0,8400	0,8580	500

Los resultados muestran un desempeño global elevado, aunque existen diferencias entre categorías. Sports presenta la mejor capacidad de discriminación, con un F1-Score de 0,9629, mientras que Business constituye la categoría de mayor dificultad, con un F1-Score de 0,8171. World y Sci_Tech presentan resultados intermedios, con F1-Scores de 0,8835 y 0,8580, respectivamente.

Debido a que el conjunto de prueba contiene exactamente 500 documentos de cada categoría, las métricas macro permiten interpretar el rendimiento otorgando el mismo peso a cada clase, sin que la distribución de observaciones favorezca a ninguna de ellas.

7. Análisis de la matriz de confusión



La matriz de confusión permite identificar cómo se distribuyen los errores del modelo entre las cuatro categorías. De los 2.000 documentos del conjunto de prueba, 1.760 fueron clasificados correctamente, en concordancia con el accuracy global de 0,8800.

Sports fue la categoría mejor diferenciada, con 480 clasificaciones correctas sobre 500 documentos. Este resultado coincide con su F1-Score de 0,9629 y muestra una separación particularmente clara respecto de las demás categorías.

La principal dificultad se concentró en la diferenciación entre Business y Sci_Tech. Se registraron 46 documentos de Business clasificados como Sci_Tech y 58 documentos de Sci_Tech clasificados como Business. Esta confusión bidireccional constituye el principal foco de error del modelo y resulta consistente con el menor F1-Score observado para Business.

También se identificaron 39 documentos de World clasificados como Business, aunque esta confusión fue de menor magnitud que la observada entre Business y Sci_Tech.

En conjunto, los errores no se distribuyen uniformemente entre las categorías. El modelo presenta una capacidad particularmente alta para reconocer noticias deportivas, mientras que encuentra mayores dificultades cuando las noticias contienen características compatibles con los dominios empresarial y tecnológico.

8. Comparación con el baseline clásico

Los resultados del Transformer se compararon con el baseline clásico desarrollado previamente mediante TF-IDF y Regresión Logística, evaluado sobre el mismo conjunto de prueba de 2.000 documentos.

El baseline clásico obtuvo un rendimiento global superior. La diferencia fue de 0,0130 en accuracy y 0,0126 en F1-Score macro a favor de TF-IDF + Regresión Logística. Por lo tanto, en las condiciones evaluadas, el uso de DistilBERT con LoRA no produjo una mejora en el desempeño predictivo global.

Modelo	Accuracy	Precision macro	Recall macro	F1 macro
TF-IDF + Regresión Logística	0,8930	0,8932	0,8930	0,8930
DistilBERT + LoRA	0,8800	0,8813	0,8800	0,8804

La comparación por categoría fue:

Categoría	F1 TF-IDF + Logística	F1 DistilBERT + LoRA	Diferencia Transformer – baseline
World	0,8900	0,8835	-0,0065
Sports	0,9553	0,9629	+0,0076
Business	0,8503	0,8171	-0,0332
Sci_Tech	0,8762	0,8580	-0,0182

La comparación por categoría muestra que la diferencia no fue uniforme. DistilBERT + LoRA superó al baseline en Sports, elevando el F1-Score de 0,9553 a 0,9629. Sin embargo, el modelo clásico obtuvo mejores resultados en las otras tres categorías.

La mayor diferencia se produjo en Business, donde el F1-Score descendió de 0,8503 con TF-IDF + Regresión Logística a 0,8171 con DistilBERT + LoRA. También se observaron diferencias a favor del baseline en World y,

en particular, en Sci_Tech.

Estos resultados muestran que la mayor complejidad del Transformer no se tradujo automáticamente en un mejor rendimiento para este problema. Si bien ambos enfoques alcanzaron resultados elevados, el baseline clásico fue superior en las métricas globales y en tres de las cuatro categorías evaluadas.

9. Discusión metodológica

Una posible explicación del desempeño observado se relaciona con la representación textual utilizada como entrada del Transformer. Para mantener la continuidad experimental del proyecto, DistilBERT recibió la variable `text_processed`, previamente generada para las etapas anteriores mediante un proceso de normalización que incluyó, entre otras transformaciones, lematización y eliminación de stopwords.

Este tipo de procesamiento resulta especialmente útil para representaciones clásicas como TF-IDF, donde reducir variaciones léxicas y términos de baja capacidad discriminativa puede simplificar el espacio de características. Sin embargo, un Transformer preentrenado como DistilBERT fue entrenado para construir representaciones contextuales a partir de secuencias cercanas al lenguaje natural y puede aprovechar información que un enfoque basado en frecuencia no representa de la misma manera, como el orden y las relaciones entre palabras, palabras funcionales y determinados signos de puntuación.

En consecuencia, utilizar el corpus previamente normalizado pudo haber reducido parte de la información contextual disponible para el Transformer y limitar parcialmente las ventajas de su arquitectura. Esta constituye una hipótesis metodológica y no una explicación causal demostrada, ya que en esta etapa no se realizó un experimento controlado comparando el mismo Transformer sobre texto original y texto procesado.

Por lo tanto, una extensión natural del experimento consistiría en entrenar DistilBERT conservando una versión del texto más próxima a su forma original y comparar sus resultados bajo las mismas condiciones de entrenamiento. Esto permitiría determinar empíricamente si el preprocesamiento aplicado contribuyó a la diferencia observada frente al baseline clásico.

10. Conclusión técnica

En esta etapa se implementó un modelo de clasificación temática basado en DistilBERT, adaptado mediante LoRA, para clasificar noticias de AG News en las categorías World, Sports, Business y Sci_Tech.

La estrategia PEFT permitió realizar el ajuste entrenando solamente 741.124 de 67.697.672 parámetros, equivalentes al 1,0948 % del modelo, y completar las tres épocas de entrenamiento en 78,58 segundos sobre una GPU NVIDIA Tesla T4. Estos resultados muestran que LoRA permitió adaptar el Transformer manteniendo una proporción reducida de parámetros entrenables.

Sobre el conjunto de prueba, DistilBERT + LoRA alcanzó un accuracy de 0,8800 y un F1-Score macro de 0,8804. Sports presentó el mejor desempeño individual, mientras que la principal dificultad se concentró en Business y, particularmente, en su diferenciación respecto de Sci_Tech.

Al comparar estos resultados con el baseline de TF-IDF + Regresión Logística, que alcanzó un accuracy de 0,8930 y un F1-Score macro de 0,8930, el modelo clásico presentó un desempeño global superior. En consecuencia, para las condiciones específicas de este experimento, el incremento de complejidad asociado al uso del Transformer no produjo una mejora predictiva que justificara su utilización frente al baseline clásico.

Este resultado no implica que el enfoque Transformer sea intrínsecamente menos adecuado para la tarea. Una limitación relevante del experimento es que DistilBERT recibió el corpus `text_processed`, previamente normalizado para las etapas anteriores. Este procesamiento favorece una representación controlada y comparable entre ramas, pero podría reducir información contextual que un Transformer preentrenado puede

aprovechar.

Por este motivo, una extensión experimental relevante consistiría en comparar DistilBERT + LoRA utilizando, bajo las mismas condiciones, el texto procesado frente a una versión más próxima al texto original. Esto permitiría evaluar empíricamente si el tratamiento previo del corpus influyó en la diferencia observada y determinar con mayor precisión en qué condiciones el enfoque Transformer puede aportar ventajas sobre el baseline clásico.